

Problemas Clássicos da Computação

Preditores Lineares e Bayesianos

Felipe Augusto Lima Reis

felipe.reis@ifmg.edu.br



**INSTITUTO
FEDERAL**
Minas Gerais

Sumário



- 1 Introdução
- 2 Regra de Bayes
- 3 Naïve Bayes
- 4 Regressão Linear
- 5 Regressão Logística
- 6 Perceptrons


Definição

- **Preditores Bayesianos:** são aqueles baseados na Regra de Bayes
 - Classificador Ótimo de Bayes;
 - Naïve Bayes;
- **Preditores Lineares:** são aqueles que realizam separação linear de conjuntos
 - Regressão Linear;
 - Regressão Logística;
 - Perceptron.

SEPARABILIDADE LINEAR

Separabilidade Linear

- Um conjunto é **linearmente separável** se existir uma hiperplano capaz de separá-lo em duas classes diferentes
 - Em duas dimensões, o hiperplano corresponde a uma reta;
 - Em três dimensões, o hiperplano corresponde a um plano;
- Esse hiperplano é chamado de **fronteira de decisão** ou **função discriminante**¹.




Fonte: [Russel and Norvig, 2013]


¹As fronteiras de decisão não são obrigatoriamente lineares.

Separabilidade Linear - Exemplos

- Exemplos de conjuntos, representados em duas e três dimensões, linearmente e não linearmente separáveis.



Fonte: [Raschka, 2015]



Fonte: Francois Fleuret at EPFL apud [Lee, 2020]

CONCEITOS BÁSICOS DE ESTATÍSTICA

Variáveis Independentes e Dependentes

- **Variáveis Independentes:** são aquelas que são manipuladas ou controladas em um experimento;
- **Variáveis Dependentes:** são aquelas cujos valores dependem da manipulação da variável independente [Reis, 2006].
 - Possível resultado (ou efeito) do experimento.


Variáveis Independentes e Dependentes

- Ex. 1: Suponha um experimento no qual deseja-se avaliar a influência da luminosidade sobre o crescimento de planta.
 - Variável independente: luminosidade;
 - Variável dependente: crescimento da planta.
- Ex. 2: Suponha um experimento no qual deseja-se avaliar a influência do *stress* sobre a frequência cardíaca.
 - Variável independente: *stress*;
 - Variável dependente: frequência cardíaca.

REGRA DE BAYES

Probabilidade Condicional².

- Suponha duas classes C_1 e C_2 , conforme distribuição abaixo;
 - É possível perceber que as duas classes possuem sobreposição;
 - Os elementos da classe C_1 são mais frequentes que os elementos da classe C_2 , ou seja, o conjunto é desbalanceado.



Fonte: [Marsland, 2014]



²Baseado em [Marsland, 2014]

Probabilidade Condicional

- Suponha uma probabilidade estimada da classe C_1 em 75%;
- Usando esse **conhecimento prévio**, temos as seguintes probabilidades: $P(C_1) = 0.75$ e $P(C_2) = 0.25$;
- Podemos definir a **probabilidade condicional** de C_1 para um dado valor x como $X : P(C_1|X)$;

Probabilidade Conjunta

- Para **quantizar**³ as medidas de x , podemos ter auxílio de um histograma⁴, computando a **probabilidade conjunta** $P(C_i, X_j)$;
 - Tal probabilidade é equivalente a medida da classe C_i em uma barra X_j do histograma;



Fonte: [Wikipedia contributors, 2020a]

³Quantificar em valores discretos.

⁴Informações básicas sobre histogramas: <https://pt.wikipedia.org/wiki/Histograma>.

Probabilidade Conjunta

- De forma semelhante, podemos interpretar $P(X_j|C_i)$ como a frequência de uma medida X_j em uma classe C_i ;
- Temos, então, duas métricas: a **probabilidade conjunta** $P(C_i, X_j)$ e a **probabilidade condicional** $P(X_j|C_i)$
- O link entre as métricas é conhecida como **Regra de Bayes**⁵;

⁵Também conhecido como Teorema de Bayes.

Regra de Bayes

- A relação entre probabilidade condicional e conjunta pode ser escrita como:

$$P(C_i, X_j) = P(X_j|C_i)P(C_i)$$

ou

$$P(C_i, X_j) = P(C_i|X_j)P(X_j)$$

- Reescrevendo as equações anteriores, temos a equação do Teorema de Bayes:

$$P(C_i|X_j) = \frac{P(X_j|C_i)P(C_i)}{P(X_j)}$$

Regra de Bayes

- De forma genérica, podemos definir, para dois eventos distintos A e B :

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

- $P(A|B)$: probabilidade condicional de um evento A ocorrer, dado que um evento B é verdadeiro;
- $P(B|A)$: probabilidade condicional de um evento B ocorrer, dado que um evento A é verdadeiro;
- $P(A)$: probabilidade à priori de um evento A ocorrer;
- $P(B)$: probabilidade à priori de um evento B ocorrer (usado para normalização das probabilidades).


$P(A)$ e $P(B)$ são conhecidas como [probabilidades marginais](#).

Regra de Bayes

- Segundo [Marsland, 2014], a Regra de Bayes “**é a equação mais importante em Aprendizado de Máquinas**”;
 - Ela relaciona a *probabilidade à posteriori* (ou posterior) $P(C_i|X_j)$ à *probabilidade à priori* $P(C_i)$ e à *probabilidade condicional de classe* $P(X_j|C_i)$.
- A importância da Regra de Bayes deriva da possibilidade de encontrar uma probabilidade à *posteriori*, a partir de cálculos simples [Marsland, 2014];

Classificador de Bayes

- É possível estimar as probabilidades à *priori*, somente pela análise de frequência no conjunto de treinamento
 - A partir da criação do histograma, é possível gerar as probabilidades condicionais de classe⁶.
- A probabilidade à *posteriori* (figura) pode ser usada em novas observações.



Fonte: [Marsland, 2014]

⁶Deve-se ressaltar que, apesar da solução apresentada, a Regra de Bayes não vale apenas para eventos discretos.

Classificador de Bayes

- Um classificador que utilize a abordagem Bayesiana deve escolher a classe de maior valor de probabilidade a *posteriori* [do Patrocínio Jr., 2018].
- Cada nova observação pode ser vinculada a uma classe C_i e um vetor de características x , usando a seguinte fórmula:

$$P(C_i|x) > P(C_j|x) \quad \forall i \neq j$$


- Essa abordagem é chamada de *Maximum à Posteriori* (MAP) e auxilia na escolha da classe de saída [Marsland, 2014]
 - Um **Classificador Ótimo de Bayes** é aquele que faz a previsão mais provável para um novo exemplo, desconhecido.

Regra de Bayes - Exemplo [Calcworkshop, 2020]

- Suponha que em um julgamento criminal por júri, tenhamos as seguintes probabilidades:
 - Condenação, caso o réu seja culpado: 82%;
 - Absolvição, caso o réu seja inocente: 80%;
- Suponha que 85% de todos os réus sejam realmente culpados.
- Suponha que um determinado réu seja condenado.
- Encontre a probabilidade dele ser inocente.

Regra de Bayes - Exemplo [Calcworkshop, 2020]

- Primeiramente, podemos criar um diagrama contendo todas as possibilidades:



Fonte: Traduzido de [Calcworkshop, 2020]


- Definida as condições, podemos calcular a probabilidade:

$$P(\text{inocente}|\text{condenado}) = \frac{P(\text{condenado}|\text{inocente}) \times P(\text{inocente})}{P(\text{condenado})}$$

$$\frac{(0.20)(0.15)}{(0.15 \times 0.2) + (0.85 \times 0.82)} = 0.0413$$

Regra de Bayes - Exemplo [Calcworkshop, 2020]

- Primeiramente, podemos criar um diagrama contendo todas as possibilidades:



Fonte: Traduzido de [Calcworkshop, 2020]

- Definida as condições, podemos calcular a probabilidade:

$$P(\text{inocente}|\text{condenado}) = \frac{P(\text{condenado}|\text{inocente}) \times P(\text{inocente})}{P(\text{condenado})}$$


$$\frac{(0.20)(0.15)}{(0.15 \times 0.2) + (0.85 \times 0.82)} = 0.0413$$

Regra de Bayes - Exemplo [Gumusbas, 2020]

- Suponha um teste de COVID-19, para identificação de possíveis doentes, com acurácia de 99%.
- Suponha, ainda, que 60% de todas as pessoas que realizam o testes estão realmente infectadas.
- Se o teste de um paciente for positivo, qual é a probabilidade de ele realmente ter a doença?

Regra de Bayes - Exemplo [Gumusbas, 2020]

- Primeiramente, podemos criar o diagrama correspondente:



Fonte: Traduzido de [Gumusbas, 2020]


- Definida as condições, podemos calcular a probabilidade:

$$P(\text{covid19}|\text{positivo}) = \frac{P(\text{positivo}|\text{covid19}) \times P(\text{covid19})}{P(\text{positivo})}$$

$$\frac{(0.99 \times 0.6)}{(0.6 \times 0.99) + (0.4 \times 0.01)} = 0.9933$$

Regra de Bayes - Exemplo [Gumusbas, 2020]

- Primeiramente, podemos criar o diagrama correspondente:



Fonte: Traduzido de [Gumusbas, 2020]

- Definida as condições, podemos calcular a probabilidade:

$$P(\text{covid19}|\text{positivo}) = \frac{P(\text{positivo}|\text{covid19}) \times P(\text{covid19})}{P(\text{positivo})}$$

$$\frac{(0.99 \times 0.6)}{(0.6 \times 0.99) + (0.4 \times 0.01)} = 0.9933$$

Naïve BAYES

Naïve Bayes

- Suponha que tenhamos um vetor de valores de *features*, com muitas características a serem avaliadas;
- O objetivo do classificador é estimar a probabilidade para cada um dos elementos:

$$P(X_j|C_i) = P(X_j^1, X_j^2, \dots, X_j^n|C_i)$$

- Suponha que cada uma das *features* sejam independentes uma das outras
 - Devido a essa característica, o classificador é chamado de *naïve* (ingênuo);
 - Na prática, muitas vezes, existe uma correlação implícita entre variáveis - que são desconsideradas pelo algoritmo.

Naïve Bayes

- Suponha a existência n diferentes características, gerando um conjunto a_1, a_2, \dots, a_n ;
- Suponha conjunto de features:

$$h_{bayes} = P(X_j^1 = a_1, X_j^2 = a_2, \dots, X_j^n = a_n | C_i)$$

- A probabilidade é dada pela multiplicação de todas as probabilidades individuais:

$$P(X_j^1 = a_1 | C_i) \times P(X_j^2 = a_2 | C_i) \times \dots \times P(X_j^n = a_n | C_i) = \prod_k P(X_j^k = a_k | C_i)$$

- O classificador Naïve Bayes selecionará a classe C_i máxima, dada pela seguinte equação: [Marsland, 2014]

$$h_{bayes}(x) = (C_i) \prod_k P(X_j^k = a_k | C_i)$$

Naïve Bayes (Notação Alternativa)

- Notação de [Shalev-Shwartz and Ben-David, 2014]
 - Um Classificador Ótimo de Bayes é definido como:

$$h_{bayes}(x) = \underset{y \in \{0,1\}}{\operatorname{argmax}} \mathcal{P}[Y = y | X = x]$$

- O classificador Naïve Bayes selecionará a classe $\mathcal{P}[Y = y]$ de maior distribuição, de acordo com a seguinte equação:

$$h_{bayes}(x) = \underset{y \in \{0,1\}}{\operatorname{argmax}} \mathcal{P}[Y = y] \prod_{i=1}^d \mathcal{P}[X_i = x_i | Y = y]$$

Naïve Bayes

- Apesar do classificador corresponder a uma simplificação, ele possui resultados comparáveis a outros métodos em alguns domínios [Marsland, 2014];
 - Onde as variáveis são realmente independentes umas das outras, o classificador produz exatamente a classificação MAP;
- Para um número de *features* d , define-se a complexidade dos algoritmos: [Shalev-Shwartz and Ben-David, 2014]
 - Ótimo de Bayes: 2^d ;
 - Naïve Bayes: $2d + 1$;

Naïve Bayes - Exemplo [Prabhakaran, 2020]

- Suponha um conjunto de 1000 frutas, que devam ser classificadas em “banana”, “maracujá” ou “outra fruta”;
- A classificação será feita com base em 3 características binárias: comprimento (longa / curta), doçura (doce / não doce) e cor (amarela / outra);
- Os dados foram compilados na seguinte tabela:

Tipo	Longa	Não Longa	Doce	Não Doce	Amarela	Não Amarela	Total
Banana	400	100	350	150	450	50	500
Maracujá	0	300	150	150	300	0	300
Outra	100	100	150	50	50	150	200
Total	500	500	650	350	800	200	1000

Adaptado de [Prabhakaran, 2020].

Naïve Bayes - Exemplo [Prabhakaran, 2020]

- Suponha que uma fruta com o seguinte aspecto: longa, doce e amarela
 - A partir das características, a fruta deverá ser classificada.
- Podemos utilizar nessa tarefa um classificador Naïve Bayes
 - Para isso, iremos avaliar, de forma independente, as probabilidades da fruta ser longa, doce e amarela;
 - A classe que tiver maior probabilidade será escolhida.

Naïve Bayes - Exemplo [Prabhakaran, 2020]

- Etapa 1: Cálculo das probabilidades individuais
 - ① Calcular probabilidades à priori:
 - $P(Y=\text{banana}) = 500/1000 = 0.5;$
 - $P(Y=\text{maracujá}) = 300/1000 = 0.3;$
 - $P(Y=\text{outra}) = 200/1000 = 0.2;$
 - ② Calcular probabilidades de cada uma das características:
 - $P(x_1=\text{longa}) = 500/1000 = 0.5;$
 - $P(x_2=\text{doce}) = 650/1000 = 0.65;$
 - $P(x_3=\text{amarela}) = 800/1000 = 0.8;$

Naïve Bayes - Exemplo [Prabhakaran, 2020]

● Etapa 2: Cálculo das probabilidades condicionais

① Banana:

- $P(x_1=\text{longa} \mid Y=\text{banana}) = 400/500 = 0.8;$
- $P(x_2=\text{doce} \mid Y=\text{banana}) = 350/500 = 0.7;$
- $P(x_3=\text{amarela} \mid Y=\text{banana}) = 450/500 = 0.9;$

② Maracujá:

- $P(x_1=\text{longa} \mid Y=\text{maracujá}) = 0/300 = 0;$
- $P(x_2=\text{doce} \mid Y=\text{maracujá}) = 150/300 = 0.5;$
- $P(x_3=\text{amarela} \mid Y=\text{maracujá}) = 300/300 = 1.0;$

③ Outra fruta:

- $P(x_1=\text{longa} \mid Y=\text{outra}) = 100/200 = 0.5;$
- $P(x_2=\text{doce} \mid Y=\text{outra}) = 150/200 = 0.75;$
- $P(x_3=\text{amarela} \mid Y=\text{outra}) = 50/200 = 0.25;$

Naïve Bayes - Exemplo [Prabhakaran, 2020]

- Etapa 3: Cálculo das probabilidades *à posteriori*

$$P(\text{Fruta}|\text{Característica}) = P(\text{Longa}|\text{Fruta}) \times P(\text{Doce}|\text{Fruta}) \times P(\text{Amarela}|\text{Fruta}) \times P(\text{Fruta})$$

- 1 Banana - $P(Y=\text{banana} \mid x=\text{longa, doce, amarela})$:
 - $P(A|B) = ((0.8 \times 0.7 \times 0.9) \times 0.5) = 0.252$
- 2 Maracujá - $P(Y=\text{maracujá} \mid x=\text{longa, doce, amarela})$:
 - $P(A|B) = ((0 \times 0.5 \times 1.0) \times 0.3) = 0$
- 3 Outra fruta - $P(Y=\text{outra} \mid x=\text{longa, doce, amarela})$:
 - $P(A|B) = ((0.5 \times 0.75 \times 0.25) \times 0.2) = 0.019$


Tipos de Classificadores Naïve Bayes

- Os principais tipos de classificadores Naïve Bayes são:
[Metsis et al., 2006] [Shin, 2020]
 - **Multinomial**: assume que cada valor $P(x_n|y)$ segue uma distribuição multinomial
 - Utilizado em problemas de classificação que contém uma frequência ou repetição de itens;
 - **Bernoulli**: aqueles em que os preditores são booleanos
 - A distribuição das variáveis utilizada é semelhante ao Naïve Bayes Multinomial;
 - **Gaussiano**: assumes que os valores contínuos são amostras de uma distribuição gaussiana.

REGRESSÃO LINEAR

Regressão Linear

- A regressão linear é uma ferramenta estatística utilizada para correlacionar uma variável dependente e uma ou mais variáveis explanatórias⁷ [Shalev-Shwartz and Ben-David, 2014];
 - Busca aprender uma função linear $h : \mathbb{R}^d \rightarrow \mathbb{R}$ que melhor se aproxima da relação entre as variáveis do problema.



Fonte: [Wikipedia contributors, 2020b]

⁷Também chamadas de variáveis independentes ou preditoras [Ribeiro Jr., 2015].

Regressão Linear

- No contexto de Aprendizado de Máquinas (AM), devem ser separados dos problemas de regressão e classificação
 - Em regressão, ajusta-se um hiperplano aos dados existentes;
 - Em classificação, busca-se um hiperplano que separa as classes [Marsland, 2014].
- Em alguns casos, os problemas de classificação podem ser transformados em regressão
 - Modo 1: adição de uma variável indicadora, que indica a classe ao qual um dado ponto pertence
 - Nesse problema, o objetivo é prever a variável indicadora, o que corresponde a uma regressão;
 - Modo 2: realizar uma regressão repetida para cada uma das classes [Marsland, 2014].

Regressão Linear



- Na regressão, faz-se uma previsão sobre um valor desconhecido \hat{y} , por meio de valores conhecidos x_i ;
- Como definido previamente, a regressão deseja obter o hiperplano que melhor se ajusta ao conjunto de dados
 - Para isso, busca-se minimizar a distância entre cada ponto e o hiperplano;
 - O objetivo é minimizar a função de erro que mede a soma de todas as distâncias.

Função de Perda

- Para cálculo da perda, é comum o uso da função **Squared-loss function**⁸: [Marland, 2014]
 - Corresponde à diferença quadrática entre o valor predito \hat{y} e o valor esperado y ;

$$\lambda(x) = (\hat{y} - y)^2$$

- A função de Risco Empírico é chamada de **Mean Squared Error (MSE)** [Shalev-Shwartz and Ben-David, 2014]
 - Os erro correspondem à soma da perda em todos os pontos;
 - A função MSE é estritamente positiva.

$$MSE = \frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i)^2$$

⁸Tradução direta: Função de perda quadrática.

REGRESSÃO LOGÍSTICA


Regressão Logística

- Regressão logística é utilizada para tarefas de classificação, onde é atribuída uma probabilidade entre 0 e 1 a cada classe [Shalev-Shwartz and Ben-David, 2014]
 - Formalmente, o objetivo é aprender uma função $h(x)$ para \mathbb{R}^d , no intervalo $[0, 1]$;
 - Em estatística, pode ser utilizada para modelar a probabilidade de um evento ou classe existir;
 - A soma das probabilidades deve ser igual a 1.

Regressão Logística

- A hipótese associada a cada classe da regressão logística é correspondente à composição da função sigmóide sobre classes de funções lineares [Shalev-Shwartz and Ben-David, 2014]
 - Na regressão logística, é utilizada a função logística

$$\sigma(t) = \frac{e^t}{e^t + 1} = \frac{1}{1 + e^{-t}}$$



Fonte: [Wikipedia contributors, 2020c]


PERCEPTRONS

Neurônios Artificiais

- O modelo de neurônio proposto por McCulloch e Pitts (1943) possuem semelhança com neurônios biológicos [da Silva, 2014]:
 - **Entrada:** sinais $\{x_1, x_2, \dots, x_n\}$ oriundos do ambiente externo;
 - **Pesos Sinápticos** (w_i): utilizado para definição de “importância” ou “relevância” das entradas para o neurônio;
 - **Bias** (w_b): entrada extra, utilizada para aumentar o grau de liberdade dos ajustes dos pesos;
 - **Corpo:** soma os produtos das entradas e pesos ($x_i \times w_i$) com o bias (w_b) e aplica a função de ativação;
 - **Função de Ativação:** controla o comportamento do sinal da saída $f(x)$ de um neurônio limitando o intervalo de valores assumidos.

Funcionamento de um Neurônio Artificial

- Funcionamento de um neurônio:
 - 1 Cada neurônio possui um sinal de entrada x_i ;
 - 2 Esse neurônio i liga-se a outro neurônio j e é capaz de propagar um valor de ativação x_i ;
 - 3 Cada ligação tem um peso numérico $w_{i,j}$ associado;




Fonte: [Russel and Norvig, 2013]

Baseado em [da Silva, 2014] e [Russel and Norvig, 2013]

Funcionamento de um Neurônio Artificial

- Funcionamento de um neurônio:
 - ④ O potencial de ativação de um neurônio é dado pela soma ponderada dos sinais de entrada, somado ao bias (w_b);

$$in_j = \sum_{i=1}^n (x_i \cdot w_i) + w_b$$




Fonte: [Russel and Norvig, 2013]

Baseado em [da Silva, 2014] e [Russel and Norvig, 2013]

Funcionamento de um Neurônio Artificial

- Funcionamento de um neurônio:
 - ⑤ Em seguida, é aplicada uma função de ativação g a essa soma, com objetivo de limitar o sinal de saída do neurônio.

$$x_j = g \left(\sum_{i=1}^n (x_i \cdot w_{ij}) + w_{0j} \right)$$



Fonte: [Russel and Norvig, 2013]

Baseado em [da Silva, 2014] e [Russel and Norvig, 2013]

Perceptrons

- *Perceptrons* são neurônios simples, propostos por Frank Rosenblatt, em 1958 [Coppin, 2004];
- Esses neurônios são utilizados para classificação de entradas em duas categorias (classificador binário);
 - Indicam se uma entrada pertence a um conjunto ou não;
 - Podem aprender operações booleanas, como AND ou OR;
 - São considerados como um tipo de classificador linear;
 - Introduziram o conceito de treinamento de neurônios e/ou redes neurais.

Perceptrons

- Um Perceptron utiliza uma função degrau (*step*) que retorna +1 se a soma de pesos da entrada X for maior que um limiar t e 0 se X é menor ou igual a t [Coppin, 2004]

$$Y = \begin{cases} +1 & \text{for } X > t \\ 0 & \text{for } X \leq t \end{cases} \quad \text{Step}(X) = \begin{cases} +1 & \text{for } X > t \\ 0 & \text{for } X \leq t \end{cases}$$

Fonte: [Coppin, 2004]

Perceptrons - Processo de Aprendizado

- Para que um Perceptron possa aprender, primeiramente ele deve passar por uma fase de treinamento [Coppin, 2004];
- Nessa fase, os pesos correspondentes às entradas são ajustados
 - Pesos podem ser considerados como indicadores de importância ou relevância das entradas.

Perceptrons - Processo de Aprendizado

- Para início do aprendizado, pesos aleatórios são definidos (em geral, entre -0.5 e +0.5) [Coppin, 2004];
- Uma entrada é dada ao Perceptron, que produz uma saída
 - A saída do Perceptron é comparada com a saída esperada;
 - Caso a saída seja incorreta, os pesos são ajustados e uma nova tentativa é feita;
 - A taxa de ajuste dos pesos é chamada de **taxa de aprendizado**, com valor típico entre 0 e 1;
 - Cada ciclo de ajuste de pesos (tentativa e avaliação de resultados) é chamada de **época**.

Perceptrons - Processo de Aprendizado

- Formalmente, a fórmula de treinamento proposta por Rosenblatt (1960) é dada por [Coppin, 2004];

$$w_i \leftarrow w_i + (\eta \times x_i \times e)$$

- Onde, η corresponde à taxa de aprendizado (*learning rate*) e e corresponde ao erro/perda (*error*).
- A equação é conhecida como Regra de Treinamento do Perceptron (*perceptron training rule*).

Perceptrons - Processo de Aprendizado

- Considere o treinamento de um perceptron para aprendizado da operação lógica OR.

Epoch	X1	X2	Expected Y	Actual Y	Error	w1	w2
1	0	0	0	0	0	-0.2	0.4
1	0	1	1	1	0	-0.2	0.4
1	1	0	1	0	1	0	0.4
1	1	1	1	1	0	0	0.4
2	0	0	0	0	0	0	0.4
2	0	1	1	1	0	0	0.4
2	1	0	1	0	1	0.2	0.4
2	1	1	1	1	0	0.2	0.4
3	0	0	0	0	0	0.2	0.4
3	0	1	1	1	0	0.2	0.4
3	1	0	1	1	0	0.2	0.4
3	1	1	1	1	0	0.2	0.4

Fonte: [Coppin, 2004]

Referências I



Calcworkshop (2020).

Bayes theorem - easily explained w/ 7 examples!

Disponível em <https://calcworkshop.com/probability/bayes-theorem/>.



Coppin, B. (2004).

Artificial Intelligence Illuminated.

Jones and Bartlett illuminated series. Jones and Bartlett Publishers, 1 edition.



da Silva, D. M. (2014).

Inteligência Artificial - Slides de Aula.

IFMG - Instituto Federal de Minas Gerais, Campus Formiga.



do Patrocínio Jr., Z. K. G. (2018).

Aprendizado de Máquina e Reconhecimento de Padrões - Conceitos Básicos / Teoria da Decisão.

Slides de Aula.



Gumusbas, E. (2020).

Bayesâ theorem 101 - example solution.

Disponível em <https://towardsdatascience.com/bayes-theorem-101-example-solution-ff54147d6c7f>.



Kopec, D. (2019).

Classic Computer Science Problems in Python.

Manning Publications Co, 1 edition.



Lee, S. (2020).

(artificial) neural networks: From perceptron to mlp.

Disponível em: https://github.com/i-Systems/tutorial/blob/gh-pages/KIM/slides/05_ANN.pdf.

Referências II



Marsland, S. (2014).

Machine Learning: An Algorithm Perspective.

CRC Press, 2 edition.

Disponível em: <https://homepages.ecs.vuw.ac.nz/~marsland/MLbook.html>.



Metsis, V., Androutsopoulos, I., and Paliouras, G. (2006).

Spam filtering with naive bayes - which naive bayes?

In The Third Conference on Email and Anti-Spam.

Disponível em http://www2.aueb.gr/users/ion/docs/ceas2006_paper.pdf.



Prabhakaran, S. (2020).

How naive bayes algorithm works? (with example and full code).

Disponível em <https://www.machinelearningplus.com/predictive-modeling/how-naive-bayes-algorithm-works-with-example-and-full-code/>.



Raschka, S. (2015).

Python Machine Learning, 1st Edition.

Packt Publishing, 1 edition.



Reis, M. M. (2006).

Conceitos elementares de estatística.

Disponível em: <https://www.inf.ufsc.br/~marcelo.menezes.reis/intro.html>.



Ribeiro Jr., P. J. (2015).

Regressão.

Disponível em: <http://leg.ufpr.br/~paulojus/CE003/ce003/node9.html>.

Referências III



Richert, W. and Coelho, L. P. (2013).
Building Machine Learning Systems with Python.
Packt Publishing Ltd., 1 edition.



Russel, S. and Norvig, P. (2013).
Inteligência artificial.
Campus - Elsevier, 3 edition.



Shalev-Shwartz, S. and Ben-David, S. (2014).
Understanding Machine Learning: From Theory to Algorithms.
Cambridge University Press, 1 edition.
Disponível em: <http://www.cs.huji.ac.il/~shais/UnderstandingMachineLearning>.



Shin, T. (2020).
How naive bayes algorithm works? (with example and full code).
Disponível em
<https://towardsdatascience.com/a-mathematical-explanation-of-naive-bayes-in-5-minutes-44adebcdb5f8>.



Wikipedia contributors (2020a).
Histograma.
Disponível em <https://pt.wikipedia.org/wiki/Histograma>.



Wikipedia contributors (2020b).
Regression analysis.
Disponível em https://en.wikipedia.org/wiki/Regression_analysis.

Referências IV



Wikipedia contributors (2020c).

Sigmoidfunktion.

Disponível em <https://de.wikipedia.org/wiki/Sigmoidfunktion>.