Sistemas Operacionais

Processos e Threads

Felipe Augusto Lima Reis felipe.reis@ifmg.edu.br



Sumário

- Conceitos
- 2 T. Contexto
- Scheduling
- 4 Comunicação
- 5 Sincronização
- Threads



- "Processo é basicamente um programa em execução" [Tanenbaum and Bos, 2014];
 - "O programa é uma entidade passiva e por si só não é um processo" [Silberschatz et al., 2012]
 - O programa somente se torna um processo quando é executado:
 - Um programa pode ter zero, um ou mais processos em execução¹.
- O processo é também definido como uma unidade de trabalho em sistemas de tempo compartilhado² [Silberschatz et al., 2012].

¹"Processo em execução" é redundante. O termo foi utilizado somente para facilitar a compreensão.

²Sistemas de tempo compartilhado são aqueles que dividem os recursos computacionais entre processos.

Tipo de Processos



- Sistemas operacionais consistem em coleções de processos:
 - Processos de sistema: executam código do sistema operacional;
 - Processos de usuário: executam código do usuário (aplicações);
- Processos de usuário e de sistema podem ser executados concorrentemente [Silberschatz et al., 2012].

T Contexto

- Atividades de CPUs podem receber diversas nomenclaturas:
 - Jobs: atividades executadas em sistemas de batch (batch systems);
 - Tarefas³: atividades executadas em sistemas de tempo compartilhado;
- Genericamente, essas atividades são denominadas processos
 - No entanto, na prática, as palavras "job", "task" (tarefa) e processo são utilizadas intercambiavelmente;
 - Recomenda-se, entretanto, o uso da palavra processo [Silberschatz et al., 2012].

³Também denominados tasks ou programas de usuários.

Na literatura, por questões históricas, a expressão "job" é utilizada no lugar de processo. Quando algumas teorias de sistemas operacionais foram desenvolvidas, a maior parte das atividades eram relativas à execução de "jobs".

Organização em Memória

T. Contexto




- Um processo em memória pode ser subdividido nas seguintes partes:
 - Text section: contém o código efetivo do programa;
 - Contém o contador do programa (program counter) e o conteúdo dos registradores do processador;
 - Data section: seção dos dados, contém as variáveis globais;
 - Pilha: contém os dados temporários (parâmetros de função, variáveis locais, endereços de retorno, etc);
 - Heap: contém os dados alocados dinamicamente (via estruturas de dados como listas, filas, pilhas, etc) [Silberschatz et al., 2012].

Organização em Memória



• Na memória, um processo pode ser visto da seguinte forma:




Organização de um processo na memória. Fonte: [Silberschatz et al., 2012]



- Os processos possuem os seguintes estados, correspondentes a sua situação atual:
 - Novo: processo em criação;
 - Em execução: processo possui instruções em execução;
 - Aguardando: processo está esperando um evento ou um recurso para continuar sua execução;
 - Pronto: processo aguarda ser atribuído a um processador;
 - Finalizado: processo terminou a execução de suas instruções [Silberschatz et al., 2012].

 A relação entre estados de um processo pode ser vista na figura abaixo:



Relação entre estados de um processo. Fonte: [Silberschatz et al., 2012]

OPERAÇÕES

Criação de Processos



- Processos podem criar inúmeros processos filhos durante sua execução
 - Esses novos processos formam uma árvore de processos:
 - Cada processo é identificado por um número único, denominado PID:
- De forma geral, todos os processos em execução são originados de um processo inicial, denominado init
 - Esse processo criado durante a rotina de boot inicializa outros processos (recursos do sistema);

Criação de Processos



- Quando um processos filhos são criados, temos as seguintes possibilidades:
 - Em relação à forma de execução:
 - Pai e filhos continuam a executar simultaneamente;
 - O pai espera até que alguns ou todos os seus filhos tenham terminado:
 - Em relação ao espaço de endereçamento:
 - O processo filho é uma cópia do processo pai (tem o mesmo programa e dados);
 - ② O processo filho possui um novo programa carregado nele [Silberschatz et al., 2012].



- Ao finalizar a execução, o processo solicita ao SO que o exclua
 - Em sistemas POSIX é utilizada a chamada exit(), enquanto no Windows é utilizada a chamada TerminateProcess()4:
 - Ao encerrar, o processo pode retornar um código para o processo pai⁵;
- Processos também podem ser encerrados pelo processo pai
 - Isso ocorre guando o processo filho não é mais necessário. utilizou uma quantidade de recursos superiores à esperada ou quando o processo pai irá finalizar;
 - Alguns SOs implementam encerramento em cascata, para que não existam processos filhos orfãos [Silberschatz et al., 2012].

⁴Conforme informado em aulas anteriores, as linguagens podem encapsular tais comandos.


⁵Em C/C++ podem ser retornados valores inteiros na rotina principal. Tal comando pode indicar que o processo foi finalizado adequadamente (0) ou mediante erro (códigos diferentes de zero).

TROCA DE CONTEXTO (CONTEXT SWITCHING)

Process Control Block (PCB)



- O Bloco de Controle de Processos (*Process Control Block*) armazena pedaços de informações relacionados ao processo;
- O PCB é composto por informações importantes como estado do processo, contador do programa, registradores, informações de uso de memória e I/O, etc.



Process Control Block. Fonte: [Silberschatz et al., 2012]



- Interrupção é um sinal que faz com que sistema operacional interrompa a tarefa atual e inicie a execução de uma rotina de kernel [Silberschatz et al., 2012];
- Interrupções podem ser divididas em 3 tipos:
 - Interrupção de Hardware: geradas por dispositivos externos (I/O), que desejam atenção do SO;
 - Interrupção de Software: programas que desejam realizar chamadas de sistema, monitoradas pelo SO;
 - Traps: correspondem a exceções ou falhas, geradas pela CPU, que requerem mudança para o modo kernel, para gerenciamento da condição excepcional⁶ [Bower, 2015].

⁶Ex.: Exceção devido à divisão de um número por zero (*DivideByZeroException*).



- Quando ocorre uma interrupção, o SO executa a operação de Troca de Contexto, correspondente às seguintes etapas:
 - Armazenamento do contexto do processo corrente⁷;
 - Suspensão do processo atual;
 - Restauração (ou carregamento) do novo processo;
 - Execução do novo processo;
 - Reinício do processo original, recuperando o contexto salvo⁸;
- O contexto de um processo é definido pelo PCB [Silberschatz et al., 2012].

⁷Esta etapa é denominada *state save* ou "salvar estado".

⁸Esta etapa é denominada state restore ou "recuperar estado".

Troca de Contexto




- A Troca de Contexto é um tipo de operação que não executa nenhum trabalho realmente útil durante a ação
 - A operação é necessária, porém não há processamento efetivo;
 - Desse modo, o procedimento deve ser o mais enxuto possível;
- A velocidade da mudança de contexto varia de acordo com o hardware e a quantidade de informação a ser copiada
 - Dependente da velocidade da memória, do número de registros a serem copiados e da existência de instruções especiais;
 - A velocidade típica é de alguns milissegundos [Silberschatz et al., 2012].

Troca de Contexto

Conceitos



 Quando um processo é interrompido, seu estado atual é salvo no PCB (e ao reiniciar, os dados são lidos da estrutura)
 [Silberschatz et al., 2012].



Process Control Block.
Fonte: [Silberschatz et al., 2012]

SCHEDULING

- Sistemas operacionais buscam maximizar o uso as CPUs
 - Para isso, em sistemas de tempo compartilhado, a CPU troca o processo em execução constantemente;
 - Essa estratégia permite que usuários interajam com múltiplas aplicações ao mesmo tempo
 - Ex.: Usuário navega na internet enquanto escuta música;
- O Agendador de Processos (Process Scheduler) é responsável pela seleção de tarefas para execução na CPU
 - Para computadores com uma única CPU, somente um processo é executado por vez;
 - Demais processos devem aguardar a finalização do processo em execução [Silberschatz et al., 2012].

Scheduling



- O scheduler utiliza um algoritmo de agendamento⁹, para escolher qual atividade será executada
 - São selecionadas tarefas cujo estado seja "pronto" (ready);
 - Processos nesse estado ficam armazenado em uma fila específica (ready queue)¹⁰
 - Essa fila segue uma estrutura semelhante às listas encadeadas:
 - Um item da fila contém o PCB e um apontamento para o próximo item da fila.

⁹Nomenclatura em inglês: scheduling algorithm.

 $^{^{10}}$ De forma geral, todos os processos existentes ficam em uma fila genérica, denominada job queue. Outras filas podem ser utilizadas para tarefas específicas (ex.: fila de espera pelo retorno de um dispositivo).


- Um processo no estado de pronto será, eventualmente, executado pela CPU;
- Durante a execução, um processo pode:
 - Requisitar acesso a I/O (será adicionado à fila de espera do dispositivo solicitado);
 - Criar processos filhos e aguardar a finalização desses processos;
 - Ser interrompido pela CPU, devido ao esgotamento do tempo disponível para execução (time-sharing)
 - O processo é interrompido e colocado novamente na fila de processos prontos para execução (esse comportamento pode se repetir inúmeras vezes).

Scheduling

Conceitos



 A sequência de estados de um processo pode ser vista na figura abaixo:



Fila de processos prontos e alteração de estados do processo. Fonte: [Silberschatz et al., 2012]

SCHEDULERS

Tipos de Schedulers

Conceitos



Threads

- Para gerenciamento de processos, existem 3 tipos principais de schedulers:
 - Long-Term Scheduler;
 - Short-Term Scheduler;
 - Medium-Term Scheduler.

T. Contexto



- Long-Term Schedulers¹¹ (Job Schedulers) são responsáveis por selecionar processos de um pool de processos (job pool) e adicioná-los à fila de prontos
 - Mesmo em um sistema de execução de batch, alguns processos precisarão esperar para executar;
- O Long-Term Scheduler é responsável por definir o grau de multiprogramação - quantos processos estão disponíveis para execução (em memória) [Shekhar, 2019].

¹¹Traducão: Agendador/Escalonador de Longo Prazo.

Long-Term Scheduler



- Long-Term Schedulers s\u00e3o executados somente quando novos processos s\u00e3o criados (o que pode demorar muitos minutos)
 - Como a frequência de execução é menor, esse escalonador pode demorar mais tempo para escolher um processo, decidindo de forma mais eficiente [Silberschatz et al., 2012];
- Esse tipo de scheduler tem um efeito de longo prazo no sistema [Shekhar, 2019].



- Long-Term Schedulers devem levar em consideração características dos processos, com relação ao seu uso de CPU e dependência de I/O;
 - I/O-bound processes: gastam mais tempo fazendo operações de I/O que processando;
 - CPU-bound processes: gastam mais tempo processando que fazendo operações de I/O;
- LTS devem combinar processos I/O-bound e CPU-bound para melhor desempenho
 - Se todos os processos dependerem de I/O, a CPU ficará ociosa;
 - Se todos os processos precisarem de processamento constante, dispositivos I/O ficarão ociosos [Silberschatz et al., 2012].

Short-Term Scheduler

T. Contexto



- Short-Term Schedulers¹² (CPU Schedulers) são responsáveis por selecionar processos na fila de prontos e definir uma CPU para executá-los
 - O processo passará para o estado de "Em execução";
- O Short-Term Scheduler é responsável por selecionar processos para melhor desempenho do sistema operacional
 - Frequentemente são utilizadas filas de prioridade, onde processos são ordenados segundo sua prioridade de execução;
 - Processos com maior prioridade são executados primeiro;

¹²Tradução: Agendador/Escalonador de Curto Prazo.

T. Contexto



- Short-Term Schedulers são executados constantemente¹³
 - A escolha de processos deve ser o mais rápida possível;
 - Quanto mais tempo demorar para escolher, mais tempo de processamento é perdido [Silberschatz et al., 2012];
- Esse scheduler tem um efeito de curto prazo, em busca de obter o maior desempenho no momento [Shekhar, 2019].

¹³Por exemplo, a cada 100ms.

Medium-Term Scheduler

T Contexto



- Medium-Term Schedulers s\(\tilde{a}\)o utilizados para colocar processos novamente na fila de processos prontos para executar¹⁴
 - Esse etapa ocorre para processos que executaram, mas não terminaram (ou seja, foram interrompidos);
 - Os processos serão executados novamente em uma nova oportunidade;
- Esse scheduler tem um efeito de médio prazo no desempenho do sistema [Shekhar, 2019].

¹⁴ Também pode ser utilizado para adicionar processos à fila de espera ou processos bloqueados.

Medium-Term Scheduler



- Medium-Term Schedulers também são responsáveis por mover processos da memória principal para secundária (e vice-versa)
 - Em alguns cenários pode ser vantajoso remover um processo da memória, reduzindo o grau de multiprogramação
 - Por exemplo, quando há pouco espaco disponível;
 - Posteriormente, o processo pode ser reintroduzido na memória;
 - Essa esquema é denominado swapping [Shekhar, 2019] [Silberschatz et al., 2012].

34 / 74



T. Contexto

Conceitos



- Processos em execução concorrente podem ser classificados em [Silberschatz et al., 2012]:
 - Processos Independentes: não podem afetar ou serem afetados por outros processos do sistema;
 - Qualquer processo que n\u00e3o compartilhe dados com outro processo é definido como independente.
 - Processos em Cooperação: podem afetar ou serem afetados por outros processos do sistema:
 - Processos que compartilham seus dados com outros.

Motivação



- Alguns motivos para cooperação entre processos são:
 - Compartilhamento de Informações:
 - Muitos usuários podem precisar de uma mesma informação:
 - Compartilhar é mais eficiente que replicar (economiza memória, evita diversas cópias para sincronização, etc);
 - Desempenho computacional:
 - Subtarefas podem ser executadas em paralelo, aumentando o desempenho do sistema;

Motivação



- Alguns motivos para cooperação entre processos são:
 - Modularidade:
 - Módulos podem ser criados e separados em diferentes processos independentes (se um módulo falhar, outros módulos continuam ativos);
 - Conveniência:
 - Tarefas diferentes podem ser executadas em paralelo;
 - Ex.: Em um programa de exibição de filmes, o player do vídeo pode executar em um processo, enquanto os comentários são exibidos em um processo diferente.




- Comunicação entre Processos (IPC)¹⁵ é o mecanismo que permite processos trocarem dados e informações [Silberschatz et al., 2012];
- Mecanismos de comunicação entre processos:
 - Memória Compartilhada:
 - Uma região de memória é compartilhada entre processos;
 - Processos podem ler e escrever informações nesse espaço;
 - Troca de Mensagens:
 - Mensagens são trocadas entre os processos (em geral, são transimitidas pequenas quantidades de informações).
 - Esse modelo evita conflitos entre os processos.

¹⁵IPC é o acrônimo de Interprocess Communication.

Comunicação entre Processos



 Os mecanismos de comunicação entre processos estão representados na figura abaixo:



Comunicação entre Processos. (a) Troca de Mensagens. (b) Memória compartilhada. Fonte: [Silberschatz et al., 2012]

Comunicação entre Processos



- Sistemas Operacionais, em geral, implementam ambos os métodos de IPC
 - Memória Compartilhada:
 - Mais rápida que a troca de mensagens, uma vez que não requer execução de chamadas de sistema;
 - Pode causar conflitos, em caso de leitura/escrita de informações desatualizadas¹⁶
 - Troca de Mensagens:
 - Mais lento, uma vez que depende da mediação do kernel;
 - Evita conflitos entre os processos [Silberschatz et al., 2012].

¹⁶ Essa situações serão descritas na seção Sincronização de Processos.

Conceitos

Comunicação entre Processos



- Segundo [Silberschatz et al., 2012], algumas pesquisas indicam que o mecanismo de Troca de Mensagens é mais eficiente que o uso de Memória Compartilhada
 - Troca de mensagens, apesar de mais lento, não necessita de mecanismos de coerência de informações¹⁷;
 - Com o aumento do número de processadores e das aplicações paralelas, os problemas de coerência de informação podem se tornar mais frequentes.

¹⁷Esses mecanismos serão descritas na secão Sincronização de Processos.

Comunicação Cliente-Servidor

Comunicação Cliente-Servidor



- Em sistemas cliente-servidor, são necessárias estratégias diferentes para comunicação entre processos;
- As estratégias mais comuns são:
 - Sockets;
 - Remote Procedure Calls;
 - Pipes.

Sockets



- Sockets são terminais para comunicação
 - Dois processos utilizam um par de sockets para se comunicar (servidor e cliente);
 - Um socket é identificado por um IP + número da porta;
 - O servidor espera por solicitações de clientes, ouvindo uma porta específica:
 - Ao receber a solicitação, o servidor aceita a conexão e troca dados/informações com o cliente;
 - Alguns serviços comuns, como HTTP, FTP, SMTP, POP3 e SSH são implementados utilizando sockets;
 - Sockets são serviços de baixo nível, portanto, somente permitem uma sequência de bytes não estruturados.

Remote Procedure Calls (RPC)



- Remote Procedure Calls (RPC) são estruturas para comunicação em conexões de rede
 - Utiliza um mecanismo de comunicação para serviços remotos;
 - RPCs são bem estruturados, não constituindo apenas de uma sequência de bytes;
 - Cada mensagem é endereçada a um daemon¹⁸ RPC em uma porta específica, identificando uma função e contendo parâmetros para execução;
 - A função é executada e o retorno é enviado ao cliente em uma mensagem separada [Silberschatz et al., 2012].

¹⁸Daemon é um programa que é executado como um processo em background.

Pipes



- Pipes são mecanismos onde a saída de um processo é direcionada para a entrada de outro
 - São estruturas de comunicação implementadas nos primeiros sistemas UNIX;
 - Fornece, um fluxo de dados unilateral entre dois processos;
 - São implementados usando Filas (FIFO);
 - Um processo escreve um item na fila e outro processo lê esse item [GeeksForGeeks, 2020] [Silberschatz et al., 2012].

SINCRONIZAÇÃO

Sincronização

Conceitos



Threads

- Processos em Cooperação são aqueles que compartilham seu espaço de endereçamento ou seus dados com outros processos;
- Esses processos podem, em algum momento, fazer acesso concorrente a um dado ou um recurso
 - Devido ao mecanismo de *scheduling*, o acesso a um recurso pode ser interrompido antes de sua completa execução;
 - Tal condição pode gerar inconsistências;
- Mecanismos de Sincronização são utilizados para evitar essas inconsistências nos dados compartilhados.

T. Contexto

Conceitos



Threads

- Considere a execução de dois processos em cooperação, P1 e P2, de uma fonte de dados compartilhada:

T. Contexto



- Considere a execução de dois processos em cooperação, P1 e P2, de uma fonte de dados compartilhada:
 - 1 P1: Lê uma variável x, de um endereço compartilhado, e copia para uma variável local (x=1);
 - P1: Incrementa a variável (x++);
 - 3 P1: Escreve o resultado na variável compartilhada (x=2).
 - P2: Lê uma variável x, de um endereço compartilhado, e copia para uma variável local (x=2);
 - ⑤ P2: Decrementa a variável (x--)
 - 6 P2: Escreve o resultado na variável compartilhada (x=1).
- O que aconteceria se o mecanismo de scheduling interrompesse a execução dos processos?

T. Contexto



- Considere a execução de dois processos em cooperação, P1 e P2, de uma fonte de dados compartilhada:
 - 1 P1: Lê uma variável x, de um endereço compartilhado, e copia para uma variável local (x=1);
 - 2 P1: Incrementa a variável (x++);
 - 3 P1: Escreve o resultado na variável compartilhada (x=2).
 - P2: Lê uma variável x, de um endereço compartilhado, e copia para uma variável local (x=2);
 - P2: Decrementa a variável (x--);
 - 6 P2: Escreve o resultado na variável compartilhada (x=1).
- O que aconteceria se o mecanismo de scheduling interrompesse a execução dos processos?



- Considere a execução de dois processos em cooperação, P1 e P2, de uma fonte de dados compartilhada:
 - 1 P1: Lê uma variável x, de um endereço compartilhado, e copia para uma variável local (x=1);
 - 2 P1: Incrementa a variável (x++);
 - 3 P1: Escreve o resultado na variável compartilhada (x=2).
 - P2: Lê uma variável x, de um endereço compartilhado, e copia para uma variável local (x=2);
 - **5** P2: Decrementa a variável (x--);
 - 6 P2: Escreve o resultado na variável compartilhada (x=1).
- O que aconteceria se o mecanismo de *scheduling* interrompesse a execução dos processos?

T. Contexto



- Considere uma nova execução de dois processos, P1 e P2, interrompida pelo mecanismo de scheduling:

T. Contexto

Conceitos

- - Considere uma <u>nova</u> execução de dois processos, P1 e P2, interrompida pelo mecanismo de *scheduling*:
 - P1: Lê uma variável x, de um endereço compartilhado, e copia para uma variável local (x=1);
 - 2 P1: Incrementa a variável (x++);
 - P2: Lê uma variável x, de um endereço compartilhado, e copia para uma variável local (x=1);
 - 4 P2: Decrementa a variável (x--);
 - 5 P1: Escreve o resultado na variável compartilhada (x=2)
 - 6 P2: Escreve o resultado na variável compartilhada (x=0
 - Conforme pode ser observado, o resultado final da execução é diferente do exemplo anterior, o que é um erro!

T. Contexto

Conceitos



- Considere uma nova execução de dois processos, P1 e P2, interrompida pelo mecanismo de scheduling:
 - 1 P1: Lê uma variável x, de um endereço compartilhado, e copia para uma variável local (x=1);
 - P1: Incrementa a variável (x++);
 - 3 P2: Lê uma variável x, de um endereço compartilhado, e copia para uma variável local (x=1);
 - P2: Decrementa a variável (x--);

T. Contexto



- Considere uma nova execução de dois processos, P1 e P2, interrompida pelo mecanismo de scheduling:
 - 1 P1: Lê uma variável x, de um endereço compartilhado, e copia para uma variável local (x=1);
 - P1: Incrementa a variável (x++);
 - 3 P2: Lê uma variável x, de um endereço compartilhado, e copia para uma variável local (x=1);
 - P2: Decrementa a variável (x--);
 - P1: Escreve o resultado na variável compartilhada (x=2).
- Conforme pode ser observado, o resultado final da execução é

T. Contexto



- Considere uma nova execução de dois processos, P1 e P2, interrompida pelo mecanismo de scheduling:
 - 1 P1: Lê uma variável x, de um endereço compartilhado, e copia para uma variável local (x=1);
 - P1: Incrementa a variável (x++);
 - 3 P2: Lê uma variável x, de um endereço compartilhado, e copia para uma variável local (x=1);
 - P2: Decrementa a variável (x--);
 - **5** P1: Escreve o resultado na variável compartilhada (x=2).
 - 6 P2: Escreve o resultado na variável compartilhada (x=0).
- Conforme pode ser observado, o resultado final da execução é

Suponha que o mecanismo de scheduling foi executado após o processamento dos itens 2 e 4.

T. Contexto



- Considere uma nova execução de dois processos, P1 e P2, interrompida pelo mecanismo de scheduling:
 - 1 P1: Lê uma variável x, de um endereço compartilhado, e copia para uma variável local (x=1);
 - P1: Incrementa a variável (x++);
 - 3 P2: Lê uma variável x, de um endereço compartilhado, e copia para uma variável local (x=1);
 - P2: Decrementa a variável (x--);
 - **5** P1: Escreve o resultado na variável compartilhada (x=2).
 - 6 P2: Escreve o resultado na variável compartilhada (x=0).
- Conforme pode ser observado, o resultado final da execução é diferente do exemplo anterior, o que é um erro!

Prof. Felipe Reis

Conceitos



52 / 74

- Conforme exemplo anterior, a ordem de execução de processos que possuem informação compartilhada pode resultar em valores incorretos, caso não exista o devido cuidado
 - Situações semelhantes ao exemplo são denominadas condições de corrida:
- Para evitar erros, é necessário estabelecer mecanismos de sincronização e coordenação
 - Ao escrever o código fonte de uma aplicação, devem ser identificadas seções cuja paralelização pode causar erros;

Sistemas Operacionais - Processos e Threads



- Seções críticas são trechos do código-fonte onde a paralelização pode causar erros, devido ao compartilhamento de informações
 - Com isso, dois processos não devem ser capazes de acessar a seção crítica em um mesmo instante;
 - Quando um processo A entrar em uma seção crítica do software, outros não poderão acessar esse trecho de código
 - Demais processos devem aguardar até que A tenha finalizado esta seção;
 - O Problema da Seção Crítica busca projetar protocolos para que processos possam usar para cooperação.

Problema da Seção Crítica



- Segundo [Silberschatz et al., 2012], o problema da seção crítica deve satisfazer os seguintes requisitos:
 - Exclusão mútua: se o processo P_i está executando sua seção crítica, nenhum outro processo pode estar executando em suas seções críticas;
 - Progresso: se nenhum processo está executando sua seção crítica e alguns processos desejam executar essa seção, a decisão será tomada apenas pelos processos interessados (e não pode ser adiada indefinidamente);
 - 3 Espera limitada: existe um limite no número de vezes que outros processos podem entrar em suas seções críticas depois que um processo fez uma solicitação de acesso à seção.

Mutex Locks

T. Contexto



- Uma das inúmeras soluções¹⁹ para o problema é denominada Mutex Locks²⁰
 - Mutex é um corresponde à abreviação de exclusão mútua (<u>mut</u>ual <u>ex</u>clusion);
- Os Mutex são utilizados para evitar condições de corrida em seções críticas do código;
- Para que um processo entre em uma seção crítica, deverá adquirir (acquire) um lock²¹, que será liberado (release) apenas ao fim da seção crítica [Silberschatz et al., 2012].

¹⁹Dentre as principais soluções, destacam-se a Solução de Perterson, os Semáforos e os Mutex Locks.

²⁰Denominado também apenas como Mutex ou apenas como Locks.

²¹Pode ser traduzido como tranca, cadeado ou fechadura. No entanto, é comum o uso do conceito em inglês.

Mutex Locks

Conceitos



Threads

- O mecanismo do Mutex pode ser visto na figura abaixo:
 - Quando um processo solicita o lock, este fica aguardando até a liberação do recurso.

```
acquire()
      while (!available)
         ; /* busy wait */
      available = false::
   do
        acquire lock
            critical section
        release lock
            remainder section
   } while (true):
         Mutex Locks.
Fonte: [Silberschatz et al., 2012]
```

Algumas linguagens, como Java, possuem comandos próprios para implementação simplificada de locks.

T. Contexto Scheduling Comunicação Sincronização 000000000000 000000 000000000000 000000000000000

DEADLOCKS

Conceitos

Threads

 T. Contexto
 Scheduling
 Comunicação
 Sincronização
 Threads


 00000
 000000000000
 00000000000
 0000000000
 0000000000

Deadlocks

Conceitos



 Deadlock corresponde a uma situação de dependência cíclica, causada por locks em diferentes recursos necessários à conclusão dos processos.




Fonte: [Stefanetti, 2018]

Deadlocks

Conceitos



- Um exemplo de *deadlock* pode ser visto na figura abaixo:
 - Processos A e B precisam de dois recursos, R₁ e R₂, para finalizarem sua execução;
 - Proc. A possui o controle de R_1 e aguarda a liberação de R_2 ;
 - Proc. B possui o controle de R_2 e aguarda a liberação de R_1 ;
 - Ambos os processos n\u00e3o liberam seu recurso, gerando um impasse [Keller, 2003].



Fonte: [Keller, 2003]

Deadlocks



- Apesar de alguns softwares conseguirem identificar deadlocks, em geral, cabe ao programador a tarefa de prevenção;
- Os deadlocks derivam obrigatoriamente das seguintes condições [Silberschatz et al., 2012]:
 - Exclusão Mútua: um recurso está bloqueado para uso exclusivo de um único processo;
 - Segurar e Esperar: o processo segura um recurso enquanto espera por outros recursos;
 - Sem Preempção: recursos somente podem ser liberados voluntariamente (não podem ser preemptados);
 - Espera Circular: um processo aguarda recursos que estão em posse de processos que aguardam recursos sob a posse de terceiros (formando um ciclo).

- Para lidar com *deadlocks*, um SO pode utilizar as seguintes abordagens: [Silberschatz et al., 2012]
 - Prevenir deadlocks, evitando que o sistema entre nesse estado;
 - Recuperar deadlocks, criando mecanismos para detecção e recuperação do problema;
 - Ignorar deadlocks, fingindo que o problema não ocorre e deixando a solução para o usuário.

Prevenção de Deadlocks

T Contexto



- A prevenção de deadlocks busca evitar ao menos uma das 4 condições obrigatórias: [Silberschatz et al., 2012]
 - Exclusão Mútua: deve-se evitar a restrição de acesso a um recurso por um único processo;
 - Segurar e Esperar: um processo somente pode solicitar um recurso se não tiver nenhum recurso bloqueado; ou deve solicitar acesso a todos os recursos de uma só vez:
 - Sem Preempção: se um processo solicita um recurso, deve obrigatoriamente liberar os recursos que possui;
 - Espera Circular: recursos devem ser numerados e divididos em tipos e cada processo deve solicitar o recursos somente em uma seguência²².

²²Ex.: Um processo pode requisitar acesso ao SSD e em seguida ao HD, mas nunca ao HD e em seguida ao SSD.

Threads

Conceitos



- Cada processo pode ser composto de uma ou múltiplas threads
 - Threads estendem do conceito de processos e permitem a execução de mais de uma tarefa por vez;
- A thread pode ser definida como a unidade básica de utilização de uma CPU [Silberschatz et al., 2012];
- Em sistemas multithreading, o PCB também inclui informações sobre threads de um processo.

Simultaneous multithreading (SMT) é uma tecnologia que permite a execução de duas ou mais threads por núcleo do processador. Alguns fabricantes adotam nomes específicos, como Hyperthreading (Intel).

Threads



- Threads podem ser traduzidas como "fio" (ou sequência) de execução de um processo
 - Tradicionalmente, os processos continham somente uma thread;
 - No entanto, sistemas modernos permitem a execução de múltiplas threads em um mesmo processo;
 - Tal característica possibilita a execução de mais de uma tarefa por vez (dentro de um processo);
 - Devido a essas características, [Tanenbaum and Bos, 2014] descrevem threads como "mini processos".

Nomenclatura

T Contexto



- Um processo tradicional contém uma única thread
 - Esses processos são denominados heavyweight process²³;
- Processos modernos, em geral, contém múltiplas threads
 - Alguns autores utilizam o termo lightweight²⁴ para diferenciar dos processos tradicionais.
- Utiliza-se, frequentemente, a nomenclatura em inglês single-thread e multi-thread para designar processos de uma e múltiplas threads, respectivamente.

²³ Traducão direta: processos peso pesados.

²⁴Traducão direta: peso leve.

Threads





- Uma thread é composta de:
 - Identificador (ID) da thread;
 - Contador de programa;
 - Conjunto de registradores;
 - Pilha;
- Uma thread compartilha com outras threads, em um mesmo processo:
 - Seção de código;
 - Seção de dados;
 - Recursos dos sistemas operacionais (ex.: arquivos abertos) [Silberschatz et al., 2012].

Organização em Memória



 Processos single e multi-threading podem ser vistos na figura abaixo.





single-threaded process

multithreaded process

Processos single-thread e multi-thread. Fonte: [Silberschatz et al., 2012]

Motivação



- Threads podem ser utilizadas para subdividir um processo
 - Ex. 1: Browser
 - Cada aba pode ser colocada em um processo diferente;
 - Na aba, threads podem ser utilizadas para diferentes tarefas como: execução do player de video, exibição de comentários, gerenciamento de caixas de texto, etc;
 - Essa subdivisão permite o processamento de forma paralela e permite uso mais amigável da aplicação;
 - Ex. 2: Servidor web
 - Um servidor web deve monitorar portas do SO (ex.: 80, 443, 8080, etc), para retornar páginas web;
 - Essa tarefa deve ser feita por um único processo;
 - Para múltiplos clientes, cada solicitação pode ser respondida em uma thread diferente.

Conceitos

Vantagens



- Sistemas multithreading possuem as seguintes vantagens: [Silberschatz et al., 2012]
 - Responsividade
 - Permite que um programa continue sua execução mesmo se parte dele estiver bloqueado ou executando operações demoradas;
 - Possibilita o aumento da capacidade de resposta ao usuário, uma vez que não é necessário aguardar a finalização de tarefas;
 - Melhora a usabilidade do sistema;
 - Compartilhamento de Recursos
 - Threads nativamente compartilham informações²⁵, ao contrário de processos, que precisam ser programados explicitamente;

²⁵Somente dentro de um mesmo processo.

Vantagens



- Sistemas multithreading possuem as seguintes vantagens: [Silberschatz et al., 2012]
 - Economia
 - Threads não necessitam de alocação de memória e criação de processos, tarefas computacionalmente caras;
 - Threads, de forma geral, são mais rápidas de serem criadas e gerenciadas²⁶;
 - Escalabilidade
 - Múltiplas threads podem ser executadas de formar paralela, permitindo maior desempenho computacional;
 - Processos de thread única podem ser executados em apenas um processador, independentemente da quantidade disponível.

²⁶No Solaris, processos são cerca de 30x mais lentos de serem criados que threads [Silberschatz et al., 2012].

Desvantagens



- Sistemas multithreading também são sujeitos a problemas de deadlocks
 - Todos os mecanismos de prevenção e recuperação de deadlocks podem ser estendidos para o gerenciamento de threads.



Deadlock.
Fonte: [Stefanetti, 2018]

Referências I





Bower, T. (2015).

Basics of how operating systems work.

[Online]; acessado em 06 de Setembro de 2021. Disponível em:

http://faculty.salina.k-state.edu/tim/ossg/Introduction/OSworking.html.



GeeksForGeeks (2020).

Ipc technique pipes.

[Online]; acessado em 07 de Setembro de 2021. Disponível em:





Keller, L. S. (2003).

Operating systems.

In Meyers, R. A., editor, Encyclopedia of Physical Science and Technology (Third Edition), pages 169–191. Academic Press, New York, third edition edition.



Shekhar, A. (2019).

What is long-term, short-term, and medium-term scheduler?

[Online]; acessado em 06 de Setembro de 2021. Disponível em:

https://afteracademy.com/blog/what-is-long-term-short-term-and-medium-term-scheduler.



Silberschatz, A., Galvin, P. B., and Gagne, G. (2012).

Operating System Concepts.

Wiley Publishing, 9th edition.

Referências II






Stefanetti, R. (2018).

Detect deadlocks in old navs.

[Online]; acessado em 08 de Setembro de 2021. Disponível em: https://robertostefanettinavblog.com/2018/04/11/detect-deadlocks-in-old-navs-2017/.



·



Prentice Hall Press, USA, 4th edition.